Spring AI 使用指南

一、Spring AI 简介

Spring AI 是 Spring 官方推出的 AI 应用开发框架，旨在简化基于大语言模型的应用程序开发。

- 提供统一的 API 抽象，支持多种 AI 模型（OpenAI、Azure、Ollama、Anthropic 等）
- 支持常见的 AI 应用场景：聊天、文本生成、图像生成、嵌入向量、语音转文字等
- 与 Spring Boot 生态无缝集成，降低 AI 应用开发门槛
- 支持 RAG（检索增强生成）模式，实现基于私有数据的问答系统

二、快速开始

1. 创建项目

访问 start.spring.io，选择所需的 AI 模型和向量存储依赖。

Spring AI 2.0.x 支持 Spring Boot 4.0.x 和 4.1.x。

2. 添加依赖

使用 Spring AI BOM 管理依赖版本：

Maven 配置：

org.springframework.ai

spring-ai-bom

2.0.0

pom

import

Gradle 配置：

dependencies {

implementation platform('org.springframework.ai:spring-ai-bom:2.0.0')

implementation 'org.springframework.ai:spring-ai-openai'

}

3. 配置 API 密钥

在 application.properties 中添加：

spring.ai.openai.api-key=YOUR_OPENAI_API_KEY

三、核心概念

1. ChatClient

ChatClient 是与 AI 模型交互的主要入口，提供流畅的 API 风格。

基本用法：

- ChatClient 用于发送消息并接收 AI 的回复
- 支持系统提示词（System Prompt）设置对话上下文
- 支持用户提示词（User Prompt）传递具体问题
- 返回 ChatResponse 对象，包含生成的文本内容

2. Prompt

Prompt 是发送给 AI 模型的输入，可以包含多个消息。

- SystemMessage：设定 AI 的角色和行为准则
- UserMessage：用户输入的问题或指令
- AssistantMessage：AI 的回复内容

3. Embedding

Embedding 将文本转换为数值向量，用于语义搜索和相似度计算。

- EmbeddingClient 提供统一的嵌入向量生成接口
- 支持多种嵌入模型，如 OpenAI text-embedding-ada-002
- 向量可用于构建 RAG 应用的语义检索基础

四、常见应用场景

1. 基础聊天应用

使用 ChatClient 构建简单的对话系统，支持多轮对话和上下文记忆。

2. RAG 问答系统

检索增强生成（Retrieval Augmented Generation）流程：

- 加载文档并将其分割成 chunks
- 使用 EmbeddingClient 将 chunks 转换为向量
- 存储到向量数据库（如 Chroma、Pinecone、Milvus）
- 用户提问时，先检索相关文档片段
- 将检索结果作为上下文，让 AI 生成准确回答

3. 图像生成

使用 ImageClient 调用 DALL-E、Stable Diffusion 等模型生成图片。

4. 语音处理

- 语音转文字：使用 AudioTranscriptionClient 调用 Whisper 等模型
- 文字转语音：使用 SpeechClient 生成语音输出

五、向量存储支持

Spring AI 支持多种向量数据库，用于存储和检索嵌入向量：

- Chroma：开源轻量级向量数据库
- Pinecone：托管式向量数据库服务
- Milvus：分布式向量数据库
- Neo4j：图数据库，支持向量搜索
- PostgreSQL + pgvector：关系型数据库的向量扩展
- Redis：内存数据库，支持向量相似度搜索

向量存储的核心操作：

- add：添加文档及其向量到存储中
- similaritySearch：根据查询向量检索最相似的文档
- delete：删除指定文档

六、最佳实践

- 使用 Spring AI BOM 统一管理依赖版本，避免版本冲突
- 合理设计 Prompt 模板，使用 SystemMessage 设定 AI 角色
- 对于生产环境，建议使用外部配置管理 API 密钥，避免硬编码

- 构建 RAG 应用时，注意文档切分策略，保持语义完整性
- 为 AI 响应设置合理的超时时间和重试机制
- 使用观察性指标监控 AI 调用的性能和成本